UNIVERSIDAD EAFIT ALMACENAMIENTO Y RECUPERACION DE LA INFORMACIÓN

PROYECTO 1 INGENIERIA DE DATOS

ESTUDIANTES:

MATEO HOLGUIN CARVALHO

DIEGO F. GUASCO LOAIZA

FABIÁN D. SÁNCHEZ MARTINEZ

ESCUELA DE CIENCIAS APLICADAS E INGENIERÍA

MAESTRÍA EN CIENCIAS DE LOS DATOS Y ANALÍTICA

EDWIN N. MONTOYA MUNERA

MARZO 15, 2024

PROYECTO 1 – Ingeniería de Datos

1. Selección de los diferentes datasets.


Para la realización del taller nos basamos en extracciones de datasets principalmente de Kaggle, del Portal de Datos Abiertos del Área Metropolitana del Valle de Aburrá y Datos del Cambio Climático del Fondo Monetario Internacional (Climate Change Dashboard – IMF).

Datasets	URL
	https://www.kaggle.com/datasets/efradgamer/world-
Avg_World_Temp_2020	average-temperature?resource=download
DefunsionesCalculadas_2008-	https://datosabiertos.metropol.gov.co/dataset/7281fa8e-
2017	<u>c666-4fed-a8bd-a4af7d0ea749</u>
Climate_Indicators_Annual_Mea	https://climatedata.imf.org/datasets/4063314923d74187be
n_Global_Surface_Temperature	9596f10d034914_0/explore
	https://www.kaggle.com/datasets/hasibalmuzdadid/global-
global air pollution dataset	<u>air-pollution-dataset</u>
	https://www.kaggle.com/datasets/patricklford/water-and-
Water Quality	air-quality?select=Cities1.csv
	https://datosabiertos.metropol.gov.co/sites/default/files/up
Temperatura	loaded resources/Datos SIATA Vaisala temperatura.json

2. Ingesta de datos como archivos / datasets desde Almacenamiento de datos en AWS S3

En este paso, se toman los archivos csv descargados previamente y se cargan dentro del bucket creado en S3, en este caso de la zona RAW.

URI S3 Raw: s3://trabajo1-raw/datasets/




3. Diseño de un datalake como almacenamiento de los datos diferentes orígenes, tipos y estructuras.

En este paso se crean las 3 diferentes zonas: Raw, Trusted y Refined como se muestra a continuación y se establece la estructura de directorios:

URI Raw: s3://trabajo1-raw/datasets/


URI Trusted: s3://trabajo1-trusted/datatrusted/

• URI Refined: s3://trabajo1-refined/datarefine/




4. Catalogación:


En este paso se transforman los datos utilizando AWS Glue, inicialmente los datos se veían así:




Posterior a la transformación, los datos quedan así, de 12 columnas quedaron 10 con un tipo de data modificado también:




Esta es una segunda transformación con AWS Glue, los datos inicialmente se cargaron así:




Y así quedaron posterior a la transformación, se redujeron a 16 columnas:





5. Proceso transformación con ETL job con AWS Glue

En este paso se usa Glue para la catalogación, indicando como zona de salida el bucket trusted



URI S3: s3://aws-glue-assets-891377086651-us-east-1/

Script (catalogación Glue – ETL Jobs)


import sys
from awsglue.transforms import *
from awsglue.utils import getResolvedOptions
from pyspark.context import SparkContext
from awsglue.context import GlueContext
from awsglue.job import Job

args = getResolvedOptions(sys.argv, ["JOB_NAME"])
sc = SparkContext()
glueContext = GlueContext(sc)
spark = glueContext.spark_session

```
job = Job(glueContext)
job.init(args["JOB NAME"], args)
# Script generated for node Amazon S3
AmazonS3_node1710014273779 = glueContext.create_dynamic_frame.from_options(
  format options={
    "quoteChar": "",
    "withHeader": True,
    "separator": ",",
    "optimizePerformance": False,
  },
  connection_type="s3",
  format="csv",
  connection_options={
    "paths": [
      "s3://trabajo1-raw/datasets/global air pollution dataset/global air pollution dataset.csv"
    "recurse": True,
  },
  transformation ctx="AmazonS3 node1710014273779",
# Script generated for node Change Schema
ChangeSchema node1710014282069 = ApplyMapping.apply(
  frame=AmazonS3 node1710014273779,
  mappings=[
    ("Country", "string", "Country", "string"),
    ("City", "string", "City", "string"),
    ("AQI Value", "string", "AQI Value", "int"),
    ("AQI Category", "string", "AQI Category", "string"),
    ("CO AQI Value", "string", "CO AQI Value", "int"),
    ("CO AQI Category", "string", "CO AQI Category", "string"),
    ("NO2 AQI Value", "string", "NO2 AQI Value", "int"),
    ("NO2 AQI Category", "string", "NO2 AQI Category", "string"),
    ("'PM2.5 AQI Value'", "string", "'PM2.5 AQI Value'", "int"),
    ("`PM2.5 AQI Category`", "string", "`PM2.5 AQI Category`", "string"),
  1.
  transformation ctx="ChangeSchema node1710014282069",
)
# Script generated for node Amazon S3
AmazonS3_node1710014287417 = glueContext.write_dynamic_frame.from_options(
  frame=ChangeSchema node1710014282069,
  connection type="s3",
  format="csv",
  connection options={
    "path": "s3://trabajo1-trusted/datatrusted/global-air-pollution/",
    "partitionKeys": [],
```

```
}, transformation_ctx="AmazonS3_node1710014287417",
```

job.commit()




6. Consultas


A continuación, se muestran unas consultas realizadas posterior a la catalogación y transformación de los datos en Athena (más adelante se muestran las consultas realizadas en Hive):


Para el dataset "global air pollution dataset":

SELECT * FROM "tpolution"."global_air_pollution_dataset" WHERE "aqi category" = 'Hazardous' AND "pm.5 aqi value" >40




Segunda consulta






Tercera consulta




7. Tablas almacenadas en Redshift desde S3 y su respectiva consulta:

Archivo cargado en Redshift




Accediendo a los datos en S3

COPY trabajo1.airpollution.airpollu FROM 's3://trabajo1raw/datasets/datasets-t1/global air pollution dataset/global air pollution dataset.csv' IAM_ROLE 'arn:aws:iam::851725270465:role/LabRole' FORMAT AS CSV DELIMITER ',' QUOTE '"' IGNOREHEADER 1 REGION AS 'us-east-1'




Consultas




SELECT country, count(city) as city_cnt FROM "trabajo1"."airpollution"."airpollu" WHERE "aqi category" = 'Hazardous' GROUP BY

country ORDER BY city_cnt DESC




8. Ecosistema Hadoop/Spark basado en AWS EMR

Desplegar clústeres EMR



Almacenamiento de datos temporales en HDFS




Creación de tabla externa en Hive desde S3 (catalogación)


USE trabajo1_fdm


CREATE EXTERNAL TABLE HDI (country STRING, city STRING, aqi_value INT, aqi_category STRING, co_aqi_value INT, co_aqi_category STRING, oz_aqi_value INT, oz_aqi_category STRING, no2_aqi_value INT, no2_aqi_category STRING, pm25_aqi_value INT, pm25_aqi_category STRING) ROW FORMAT DELIMITED FIELDS TERMINATED BY ',' STORED AS TEXTFILE


LOCATION 's3://trabajo1-raw/datasets/global air pollution dataset/'




Consultas:











Instalación de un ambiente de procesamiento en Spark con pyspark (se adjunta notebook con scripts)















In [74]: df.write.format('csv').option('header','true').save('s3://trabajo1-refined/datarefine/water_quality/df_csv',mode='overwrite')

URI S3 archivo exportado: s3://trabajo1-refined/datarefine/water quality/



Notebook creado en S3 desde jupyterhub

URI S3: s3://mholguinc2notebooks/jupyter/

